


ESTIMACIÓN DE COSECHA CON MPU



ALEJANDRO GÓMEZ

ÍNDICE




01	OBJETIVOS DEL PROYECTO
02	¿QUÉ ES UNA NPU?
03	HARDWARE Y SOFTWARE
04	DATASET
05	DESARROLLO DEL MODELO DE IA
06	PRUEBAS Y RESULTADOS
07	CONCLUSIONES



OBJETIVOS DEL PROYECTO



DESARROLLAR UN SISTEMA AUTOMATIZADO DE ESTIMACIÓN DE COSECHA MEDIANTE PROCESAMIENTO DE IMÁGENES UTILIZANDO UNA UNIDAD DE PROCESAMIENTO NEURONAL PARA OPTIMIZAR EL CONTEO DE FLORES Y PREDECIR EL RENDIMIENTO PRODUCTIVO



¿QUÉ ES UNA NPU?



01

ORIGEN

02

CARACTERÍSTICAS


03

¿CÓMO
FUNCIONAN?


04

NPU VS GPU VS
PROC. VECTORIALES

¿QUE ES UNA NPU?



UNIDAD DE PROCESAMIENTO NEURONAL
MICROPROCESADOR ESPECIALIZADO
IMITA LA FUNCIÓN DE PROCESAMIENTO DEL CEREBRO
OPTIMIZADAS PARA REDES NEURONALES, DEEP LEARNING Y MACHINE LEARNING



CPU - USO GENERAL
GPU - CÁLCULOS MATEMÁTICOS
NPU - ACELERAR TAREAS Y **CARGAS DE TRABAJO IA**. CÁLCULO DE **CAPAS DE REDES NEURONALES**

ORIGEN DE LAS NPU



CPU - ARQUITECTURA DONDE LOS DATOS VIAJAN ENTRE MEMORIA Y PROCESADOR
LA IA REQUIERE MOVER **BILLONES DE DATOS SIMULTÁNEAMENTE**

1980 - PRIMEROS CHIPS NEURONALES

GPU - MEJORES QUE LAS CPU PARA IA. MAYOR CONSUMO

2016 - **GOOGLE CREA LA PRIMERA TPU CREADA** PARA ACELERAR LOS CÁLCULOS DE LAS REDES NEURONALES

2017 - **APPLE Y HUAWEI FUERON PIONEROS EN NPU.** APPLE CON NEURAL ENGINE EN **A11 BIONIC** Y HUAWEI CON EL NPU **KIRIN 970**



CARACTERÍSTICAS DE LAS NPU

PROCESAMIENTO PARALELO - DESCOMPONE PROBLEMAS GRANDES EN COMPONENTES PARA PROBLEMAS MULTIMEDIA


ARITMÉTICA DE BAJA PRECISIÓN - ADMITEN OPERACIONES 8 BITS (O MENOS) REDUCIENDO COMPLEJIDAD COMPUTACIONAL

MEMORIA DE GRAN ANCHO DE BANDA - PARA REALIZAR CON EFICACIA TAREAS DE PROCESAMIENTO IA


ACELERACIÓN DE HARDWARE - ARQUITECTURA DE MATRIZ SISTÓLICA O DE PROCESAMIENTO DE TENSORES MEJORADO

PROCESAMIENTO DE DATOS MULTIMEDIA EN TIEMPO REAL - RESPONDER MEJOR A GRANDES ENTRADAS DE DATOS, INCLUIDAS IMÁGENES, VÍDEO Y VOZ


EFICIENCIA MEJORADA - PROCESAMIENTO PARALELO MUCHO MÁS EFICIENTE QUE LAS GPU



FUNCIONAN SIMULANDO EL COMPORTAMIENTO DE LAS NEURONAS HUMANAS PERMITIENDO PROCESAMIENTO CONJUNTO DE INSTRUCCIONES DE DEEP LEARNING
NO ESTÁN DISEÑADAS PARA CALCULOS PRECISOS, SI NO PARA RESOLUCIÓN DE PROBLEMAS APRENDIENDO DE TIPOS DE DATOS Y ENTRADAS
NO ESTAN DISEÑADAS PARA SUSTITUIR A LAS CPU Y GPU. SU ARQUITECTURA MEJORA EL DISEÑO DE AMBOS EN PARALELISMO Y MACHINE LEARNING





NPU VS GPU VS PROC. VECTORIALES



CARACTERÍSTICAS	NPU	GPU	PROCESADORES VECTORIALES
ARQUITECTURA	CIRCUITOS DE LÓGICA FIJA EXCLUSIVOS PARA OPERACIONES MAC.	MILES DE NÚCLEOS PEQUEÑOS Y PROGRAMABLES (ALU).	-
MEMORIA	INTERNA, PEQUEÑA Y RÁPIDA (SRAM).	GRAN ANCHO DE BANDA (VRAM), ALTO CONSUMO DE ENERGÍA.	-
PRECISIÓN	BAJA PRECISIÓN (8 O 16 BITS) PARA AHORRAR ENERGÍA.	-	ALTA PRECISIÓN (32 O 64 BITS) PARA CÁLCULOS CIENTÍFICOS.
PROCESAMIENTO	TENSORES (BLOQUES 3D O MÁS) PARA PROCESAR CAPAS DE REDES NEURONALES.	RENDERIZAR VIDEOJUEGOS O SIMULAR FLUIDOS.	VECTORES (INSTRUCCIÓN A UNA LARGA FILA DE DATOS).
SIMILITUDES	PARALELISMO MASIVO (COMO LA GPU) Y PRINCIPIO SIMD (COMO EL VECTORIAL).	PARALELISMO MASIVO.	PRINCIPIO SIMD (UNA INSTRUCCIÓN, MÚLTIPLES DATOS).

HARDWARE Y SOFTWARE




RASPBERRY PI 5 - 8GB RAM. PROCESADOR CORTEX-A76 (2,4GHZ)

AI HAT+ HAILO-8 - 26 TOPS DE POTENCIA

CAMERA MODULE V2.1 - INTEGRACION CON RPICAM-APPS

RASPBERRY PI OS - 64 BITS



SISTEMA COMPLEMENTARIO

AMD RYZEN 5 3500U

8GB RAM DDR4

LINUX MINT 22.3 "ZENA" BASADO EN UBUNTU 24.04 LTS

DATASET






01

HERRAMIENTAS Y
ESTRUCTURA

02

ETIQUETADO Y
SEGMENTACIÓN

HERRAMIENTAS Y ESTRUCTURA



MODULO PYTHON VENV - ENTORNO PYTHON PARA INSTALAR DEPENDENCIAS Y PAQUETES
LABEL STUDIO - HERRAMIENTA DE ETIQUETADO DE IMAGENES
YOLOV8 - MODELO A ENTRENAR CREADO POR ULTRALYTICS

ETIQUETADO Y SEGMENTACIÓN



CONFIGURACIÓN DE PROYECTO



SELECCIÓN DE TIPO DE TAREAN - DETECCIÓN DE
OBJETOS CON CAJAS DELIMITADAS

DEFINICIÓN DE ETIQUETAS - UNICAMENTE LA FLOR

IMPORTACIÓN DE DATOS

PROCESO DE ANOTACIÓN MANUAL

EXPORTACIÓN DEL DATASET - FORMATO YOLO



DESARROLLO DEL MODELO IA



01

ARQUITECTURA DE
LA RED NEURONAL

02

ENTRENAMIENTO
Y VALIDACIÓN

03

GRÁFICAS

04

OPTIMIZACIÓN Y
CUANTIZACIÓN


ARQUITECTURA DE LA RED NEURONAL




PARADIGMA DEEP LEARNING - EXTRAER CARACTERÍSTICAS SEMÁNTICAS COMPLEJAS PARA IDENTIFICAR LAS FLORES

YOLOv8

- EFICIENCIA COMPUTACIONAL
- DISEÑO SINGLE-SHOT DETECTOR - UNA ÚNICA PASADA POR LA IMAGEN
- COMPATIBILIDAD HARDWARE




ENTRENAMIENTO Y VALIDACION



ENTORNO VIRTUAL AISLADO
23 IMAGENES DE ENTRENAMIENTO Y 5 DE VALIDACIÓN CON 79 INSTANCIAS

Epoch 8/100	GPU_mem 0G	box_loss 1.464	cls_loss 1.907	df_l_loss 1.46	Instances 43	Size 640: 100%	2/2 4.2s/it 8.3s
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%
	all	5	79	0.0293	0.557	0.0575	0.0302
Epoch 9/100	GPU_mem 0G	box_loss 1.455	cls_loss 1.828	df_l_loss 1.501	Instances 76	Size 640: 100%	2/2 4.3s/it 8.5s
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%
	all	5	79	0.0293	0.557	0.089	0.0455
Epoch 10/100	GPU_mem 0G	box_loss 1.395	cls_loss 1.804	df_l_loss 1.433	Instances 85	Size 640: 100%	2/2 4.2s/it 8.5s
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%
	all	5	79	0.0353	0.671	0.153	0.0703
Epoch 11/100	GPU_mem 0G	box_loss 1.478	cls_loss 1.86	df_l_loss 1.469	Instances 46	Size 640: 100%	2/2 4.3s/it 8.5s
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%
	all	5	79	0.0387	0.734	0.19	0.09
Epoch 12/100	GPU_mem 0G	box_loss 1.356	cls_loss 1.589	df_l_loss 1.392	Instances 69	Size 640: 100%	2/2 4.3s/it 8.6s
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%
	all	5	79	0.04	0.759	0.179	0.0929
Epoch 13/100	GPU_mem 0G	box_loss 1.364	cls_loss 1.707	df_l_loss 1.365	Instances 49	Size 640: 100%	2/2 4.4s/it 8.8s
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%
	all	5	79	0.0387	0.734	0.158	0.0857
Epoch 14/100	GPU_mem 0G	box_loss 1.189	cls_loss 1.54	df_l_loss 1.264	Instances 58	Size 640: 100%	2/2 4.3s/it 8.6s
	Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%
	all	5	79	0.0407	0.772	0.165	0.0928
Epoch	GPU_mem	box_loss	cls_loss	df_l_loss	Instances	Size	

100 EPOCHS
IMÁGENES DE RESOLUCIÓN 640X640 PX
CPU DE PRECISIÓN FLOTANTE DE 32 BITS





GRÁFICAS

TRAIN/BOX_LOSS Y VAL/BOX_LOSS -
CURVA DE VALIDACIÓN CON
TRAYECTORIA DESCENDENTE. NO
HAY SOBRE AJUSTE


TRAIN/CLS_LOSS Y VAL/CLS_LOSS -
CAIDA DRÁSTICA EN LOS 20
PRIMEROS EPOCHS

TRAIN/DFL_LOSS Y VAL/DFL_LOSS -
AFINA LOS BORDES DE LA CAJA
CUANDO ESTAN PEGADOS A OTROS
OBJETOS

METRICS/PRECISION(B) -
85.4% DE PRECISIÓN


METRICS/RECALL(B) -
55.7% PARA EVITAR FALSAS HOJAS

METRICS/MAP50 -
61.7% DE ÉXITO CON LA MÉTRICA
YOLO




An abstract graphic featuring three interlocking, curved, ring-like shapes. Each shape is rendered with a vibrant, multi-colored gradient, transitioning through shades of purple, magenta, red, orange, yellow, and green. The shapes are set against a solid black background, creating a high-contrast, visually striking composition. The curves of the shapes suggest movement and a three-dimensional quality.

FASE DE CUANTIZACIÓN Y OPTIMIZACIÓN (HEF) - CUANTIZACIÓN POST-ENTRENAMIENTO MAPEANDO EL FP32 A VALORES ENTEROS DISCRETOS INT8 OPTIMIZANDO EL ANCHO DE BANDA



PRUEBAS Y RESULTADOS



VIDEO FORMATO MP4 CON 479 FOTOGRAMAS

MÉTRICA DE RENDIMIENTO	SISTEMA COMPLEMENTARIO (CPU RYZEN 5)	RASPBERRY PI 5 (CPU NV)	RASPBERRY PI 5 + NPU HAILO-8
TIEMPO TOTAL (S)	35.92	205.56	10.92
VELOCIDAD PROMEDIO (FPS)	13.33	2.33	43.85
TIEMPO MEDIO POR FRAME (MS)	74.99	429.14	22.8
PROYECCIÓN DE LA PARCELA (T)	0.03	0.06	1.58

VELOCIDAD DE MUESTREO EN EL BUFFER DE OPENCV - PROCESAR A 2.33 FPS, EL SISTEMA SUFRE UNA PÉRDIDA MASIVADE FOTOGRAMAS POR SEGUNDO

CONCLUSIONES

01

LIMITACIONES
ENCONTRADAS

02

POSIBLES
MEJORAS



CONCLUSIONES



- **YOLOV8N** HA DEMOSTRADO SER UNA METODOLOGÍA ROBUSTA PARA LA TELEDETECCIÓN EN ENTORNOS AGRÍCOLAS COMPLEJOS CON **85.4% DE PRECISIÓN GLOBAL Y UN MAP50 DEL 61.7%**
- LA **REDUCCIÓN** DEL TAMAÑO DE LOS DATOS A INT8 NO **PROVOCÓ DEGRADACIÓN Y BENEFICIO A LA EFICIENCIA DEL NPU**
- **EN LA NPU** LA TASA DE REFRESCO AUMENTÓ UN 1782% RESPECTO A LA EJECUCIÓN NATIVA EN LA RASPBERRY PI 5


LA ACELERACIÓN POR HARDWARE ES EL ÚNICO CAMINO VIABLE PARA EVITAR LA PÉRDIDA DE INFORMACIÓN EN MUESTREOS DINÁMICOS DE CAMPO

LIMITACIONES ENCONTRADAS

- **FALLO EN LA CÁMARA** - POR ELLO DECIDIMOS USAR UN VIDEO MP4
- **VULNERABILIDAD FÍSICA DEL HARDWARE** - PUERTOS DE LA RASPBERRY DELICADOS
- **AUSENCIA DE MODELOS PREENTRENADOS** - DADA LA ESPECIFICIDAD DEL MODELO
- **RESTRICCIONES DEL FABRICANTE** - EL SOFTWARE DE OPTIMIZACIÓN DE HAILO TIENE ARQUITECTURA CERRADA Y DISTRIBUCIÓN RESTRINGIDA



FUTURAS MEJORAS



- **FACTOR DE CORRECCIÓN DE DENSIDAD FOLIAR** - AÑADIR UN COEFICIENTE MATEMÁTICO QUE COMPENSE LA ESTADÍSTICA DE FLORES OCULTAS BAJO LA DENSIDAD FOLIAR MEJORANDO LA PRECISIÓN
- **CALIBRACIÓN MEDIANTE CUANTIZACIÓN CONSCIENTE DEL ENTRENAMIENTO:** EN LUGAR DE UN POST-ENTRENAMIENTO ESTÁNDAR SOBRE EL ONNX USAR QUANTIZATION-AWARE TRAINING (QAT) QUE SIMULA INT8 DURANTE EL ENTRENAMIENTO EN EL PORTATIL MINIMIZANDO LA DEGRADACIÓN E IMPRECISIÓN DEL HEF
- **DISEÑO DE CARCASA**
- **AUTOMATIZACIÓN DE PARÁMETROS AGRONÓMICOS** - CREAR UNA INTERFAZ DE USUARIO EJECUTABLE DIRECTAMENTE EN LA RASPBERRY PI



GRACIAS

ESTIMACIÓN DE COSECHA CON NPU

ALEJANDRO GÓMEZ