

Tema 6

Evaluación de Sistemas Informáticos. Modelado

Objetivos



Proporcionar un modelo analítico de comportamiento de un sistema informático como punto de partida para obtener índices de rendimiento.



Entender la importancia de los cuellos de botella como limitadores del rendimiento de los sistemas informáticos.



Saber aplicar las leyes operacionales en ejemplos sencillos para obtener índices de rendimiento.



Saber interpretar los límites asintóticos u optimistas del rendimiento que establece el análisis operacional.



Saber evaluar de forma cuantitativa el efecto sobre el rendimiento de un computador de diferentes terapias de mejora o estrategias de diseño



Saber evaluar de forma cuantitativa el efecto sobre el rendimiento de un computador de diferentes terapias de mejora o estrategias de diseño.

Bibliografía



Evaluación y modelado del rendimiento de los sistemas informáticos. X. Molero, C. Juiz, M. Rodeño. Pearson Educación, 2004. Capítulos 4 y 5.



The art of computer system performance analysis. R. Jain. John Wiley & Sons, 1991. Capítulos 30, 32, 33 y 34.



Measuring computer performance: a practitioner's guide. David J. Lilja, Cambridge University Press, 2000. Capítulo 11.

Contenidos

Introducción.

Redes de colas de espera.


Variables y leyes operacionales.

Límites asintóticos del rendimiento.

Algoritmos de resolución de redes de colas.



Técnicas de mejora del rendimiento.

¿Cómo podemos **evaluar**? (medir, predecir o comparar el rendimiento)



El modelo de un sistema informático


- Modelo: abstracción del sistema informático real.
 - Conjunto de dispositivos interrelacionados y trabajos que los usan (carga).
 - Dispositivos (*resources*): procesador, discos, memoria, red, etc.
 - Trabajos (*jobs*): programas, transacciones, peticiones, etc.
 - Normalmente un dispositivo o recurso solo puede ser usado por un trabajo a la vez. El resto habrá de esperar.
- Modelos basados en redes de colas (*queueing networks*).
 - Introducidos en la década de 1950.
 - Objetivo: cálculo del tiempo de respuesta que experimenta un trabajo procesado por un sistema informático.
 - Aproximación estadística.
- Otros modelos: redes de Petri, cadenas de Markov.




Ejemplos de diferentes modelos




Sistema real



Redes de Petri



Cadenas de Markov



Redes de Colas

El análisis operacional

Presentado por Denning y Buzen en 1978.

Basado en magnitudes medibles (*variables operacionales*) del sistema informático.

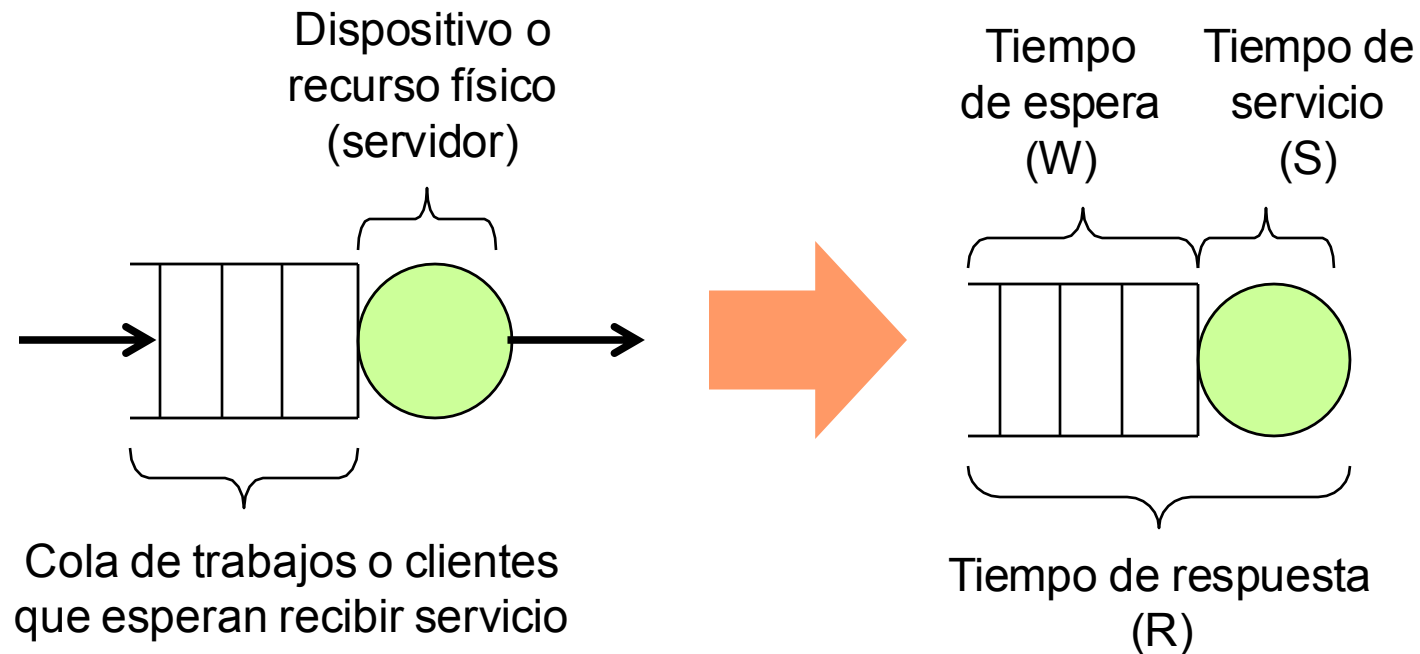


Leyes operacionales: relaciones entre las magnitudes medibles.

Límites asintóticos de las prestaciones por medio de cálculos muy sencillos (*back on the envelope calculations*).

Concepto de estación de servicio

Estación de servicio (*service station*): Objeto abstracto compuesto por un dispositivo (recurso físico) que presta un servicio y una cola de espera para los trabajos (clientes) que demandan un servicio de él.



Variables temporales de una estación de servicio

Tiempo de espera en cola (W)

Tiempo transcurrido desde que un trabajo quiere hacer uso de un recurso hasta que realmente empieza a utilizarlo.


Tiempo de servicio (S)

Tiempo transcurrido desde que un trabajo hace uso de un recurso hasta que lo libera.

Tiempo de respuesta de la estación de servicio (R)

Suma de los dos tiempos anteriores.

$$R = W + S$$



Configuración y Evaluación de Sistemas Informáticos


Ejemplo 1

Suponga que una estación de servicio tiene un tiempo de servicio constante $S=1s$. Suponga que los trabajos llegan con la siguiente distribución temporal:

Durante los primeros 5 segundos no llega ningún trabajo.


En $t=5s$ llegan 3 trabajos: J1, J2 y J3 (por ese orden).

Calcule los tiempos de espera en la cola y los tiempos de respuesta que experimentan cada uno de los tres trabajos. Calcule finalmente los valores medios de W y R.




Estaciones con más de un servidor

Son capaces de atender a más de un trabajo en paralelo:




3 servidores
idénticos




Infinitos servidores: no
hay espera en cola.
 $R=S$ (tipo retardo)

Un par de modelos sencillos





Biprosesador



Tiempo de servicio: tiempo de ejecución del proceso en el sistema

Disco




Tiempo de servicio: posicionamiento más latencia rotacional más transferencia

El tiempo de reflexión (*think time*)


Es un parámetro (Z) que modela el tiempo que requiere el usuario antes de volver a lanzar una petición al sistema informático.

Se suele modelar mediante una estación de servicio tipo retardo con un tiempo de servicio = Z .



Redes de colas: concepto

Conjunto de estaciones de servicio conectadas entre sí.
Cada recurso del sistema viene modelado mediante una estación de servicio.



El modelo de servidor central

Es el modelo que más se ha utilizado para representar el comportamiento de los programas en un sistema informático.

¿Cuál es este comportamiento?

Un trabajo que llega al sistema comienza utilizando el procesador.

Después de dejar el procesador, el trabajo puede:

terminar (sale del sistema), o bien

realizar un acceso a la unidad de entrada/salida (discos, red,...).


Después de una operación con una unidad de entrada/salida, el trabajo vuelve al procesador.

Recursos considerados

Procesador

Entrada/salida: unidades de disco magnético, óptico, red, etc.

Modelo de servidor central: Diagrama básico de conexión



Propiedad: Cada trabajo que abandona el modelo (=proceso ejecutado) ha “visitado” la CPU tantas veces como la suma de sus “visitas” a cada uno los dispositivo de E/S más 1.


Red de colas abierta

Los trabajos llegan a la red a través de una fuente externa. Tras ser procesados, salen de ella a través de uno o más sumideros.

Se usa para sistemas cuyo número de trabajos (N) puede variar con el tiempo.

Se parte de una tasa de llegada de trabajos conocida (λ).

Objetivo del modelo: cálculo del tiempo de respuesta (R) y del número de trabajos (N) que se encuentran por término medio dentro el sistema.



Red de colas cerrada



Presenta un número constante de trabajos en el sistema (N) que van recirculando por el mismo.

Sistemas con cargas (número de trabajos) por lotes (*batch*).

Sistemas con cargas (número de trabajos) con interacción del usuario.

Tiempo de reflexión (Z , *think time*).


Objetivo: cálculo del tiempo medio de respuesta (R) y de la productividad media (X) del sistema.



Redes de colas mixtas


Más de un tipo de carga que hace uso del sistema.

Ejemplo: sistema con carga interactiva y transaccional.



Tiempo medio de respuesta (R)


Se mide desde que el trabajo entra al sistema hasta que lo “abandona”.



Variables y leyes de operaciones

Variables: sistema vs estación de servicio

- El sistema contiene K estaciones de servicio (recursos o dispositivos).
- Las variables se miden mediante monitorización o se estiman mediante especificaciones técnicas del hardware
- A todo el sistema en su globalidad lo denotamos como dispositivo “cero”.



Variables operacionales básicas

Variable global temporal


T Duración del periodo de medida en el que se extrae el modelo.

Variables relacionadas con el dispositivo i

A_i Número de trabajos solicitados (llegadas, *arrivals*).

C_i Número de trabajos completados (salidas, *completions*).

B_i Tiempo que el dispositivo está ocupado (*busy time*).



Variables operacionales deducidas

Ya conocidas:

λ_i Tasa de llegada (*arrival rate*)

X_i Productividad (*throughput*)

S_i Tiempo de servicio (*service time*)

W_i Tiempo de espera en cola (*waiting time*)

R_i Tiempo de respuesta (*response time*)

τ_i Tiempo entre llegadas (*interarrival time*)

trabajos/segundo

trabajos/segundo

segundos/trabajo

segundos/trabajo


segundos/trabajo

segundos

$$S_i = \frac{B_i}{C_i}$$

$$R_i = w_i + S_i$$

$$\tau_i = \frac{1}{\lambda_i} = \frac{T}{A_i}$$




Estación de servicio i

Variables operacionales deducidas (II)

Utilización U_i (*utilization*): Es la proporción de tiempo que el dispositivo ha estado en uso (B_i) con respecto al intervalo total de medida (T). Es una variable adimensional. Coincide con el número medio de trabajos siendo servidos por el dispositivo (como máximo 1 si $B_i=T$).

Q_i Número medio de trabajos en cola de espera (*waiting jobs*) por unidad de tiempo.

N_i Número medio de trabajos en la estación de servicio (cola más recurso) por unidad de tiempo. Se cumple que $N_i = Q_i + U_i$.




Ejemplo 2

Suponga que la estación de servicio i -ésima de una red de colas tiene un tiempo de servicio constante $S_i=1s$. Suponga que los trabajos llegan con la siguiente distribución temporal:

Durante los primeros 5 segundos no llega ningún trabajo.

En $t=5s$ llegan 3 trabajos: J_1 , J_2 y J_3 (por ese orden).


Para el intervalo de medida $[0, 10]s$, calcule A_i , B_i , C_i , λ_i , τ_i , X_i , Q_i , N_i , U_i .



$$A_i = 3 \text{ trabajos}, \quad B_i = 3s, \quad C_i = 3 \text{ trabajos}, \quad \lambda_i = X_i = 3/10 = 0.3 \text{ trabajos/s}, \quad \tau_i = 3.3 s$$

Ejemplo 2 (cont.)

Cálculo de la utilización media (U_i) y del número medio de trabajos en la cola (Q_i) y en la estación (N_i).



Estación de servicio i

$$U_i = \frac{B_i}{T} = \frac{3}{10} = 0.3$$

$$Q_i = \frac{0 \times 5s + 2 \times 1s + 1 \times 1s + 0 \times 3s}{10} = 0.3$$

$$N_i = \frac{0 \times 5s + 3 \times 1s + 2 \times 1s + 1 \times 1s}{10} = 0.6$$

Otras formas alternativas de calcular U_i :

$$U_i = N_i - Q_i = 0.3$$

$$U_i = \frac{0 \times 5s + 1 \times 3s + 0 \times 2s}{10} = 0.3$$

Las variables del sistema en su conjunto

Variables básicas

A_0 Número de trabajos solicitados al sistema (*arrivals*).

C_0 Número de trabajos completados por el sistema (*completions*).


Variables deducidas

λ_0 Tasa de llegada al sistema (*arrival rate*).

X_0 Productividad del sistema (*throughput, bandwidth*).

R_0 Tiempo de respuesta del sistema (*response time, latency*).

N_0 Número medio de trabajos en el sistema (#jobs).



Razón de visita y demanda de servicio

Razón de visita V_i (*visit ratio*). Representa la proporción entre el número de trabajos completados por el sistema y el número de trabajos completados por el dispositivo. Es como si el trabajo tuviera que “visitar” el dispositivo V_i veces antes de poder abandonar el sistema. Es una variable adimensional.

$$V_i = \frac{C_i}{C_0}$$

Demanda de servicio D_i (*service demand*). Tiempo total de uso del dispositivo “demandado” por cada trabajo que abandona el sistema.

$$D_i = \frac{B_i}{C_0} = V_i \times S_i$$

Nótese que la demanda de servicio no tiene en cuenta la posible espera en cola.

Ejercicio

Después de monitorizar el **procesador** de un servidor web durante un periodo de **30** segundos, se sabe que ha sido utilizado durante **27** segundos. Asimismo, se han contabilizado durante ese periodo un total de **74** peticiones de ejecución de procesos al procesador y un total de **72** procesos ejecutados (=peticiones al procesador completadas). Se ha estimado que cada petición al servidor web requiere la ejecución de una media de **cuatro** procesos (=visitas al procesador), calcule:

- a) ¿Cuál es la tasa de llegada al procesador?
- b) ¿Cuál es la productividad del procesador?
- c) Determínese la utilización del procesador, su tiempo de servicio y su demanda de servicio.
- d) ¿Cuál es la productividad del servidor web?

Leyes operacionales

Todas las variables operacionales son **valores medios** para el intervalo de monitorización T. Por tanto, el valor de las variables operacionales depende del intervalo de observación T.

Existen, sin embargo, una serie de relaciones entre las variables operacionales que se mantienen válidas para cualquier intervalo de observación y que no dependen de suposiciones sobre la distribución de los tiempos de servicio o de la forma en la que llegan los trabajos. **Leyes operacionales.**

Estas leyes son tanto más útiles cuando se cumple la **hipótesis del equilibrio de flujo** que establece que en un Sistema Informático no saturado, si se escoge un intervalo de observación suficientemente largo, se cumple que:

El número de trabajos que llegan al servidor coincide aproximadamente con el que sale ($A_o \approx C_o$). Dicho de otra manera, la tasa de llegada coincide aproximadamente con la productividad ($\lambda_o \approx X_o$).

$$\frac{|A_{\#} - C_{\#}|}{C_{\#}} \approx 0 \quad \longrightarrow \quad \lambda_{\#} \approx X_{\#}$$


El número de trabajos que llegan a cada estación de servicio coincide aproximadamente con el que sale: ($\lambda_i \approx X_i, \forall i=1...K$).

Ley de Little (1961)

Relaciona el número medio de trabajos en el sistema (N_0) con el tiempo de respuesta (R_0) y su tasa de llegada (λ_0).

$$N_0 = \lambda_0 \times R_0$$


Bajo la hipótesis del equilibrio de flujo, esta ley relaciona las tres variables más importantes que reflejan el rendimiento de un Sistema Informático: N , X y R .




Esta ley puede ser aplicada no solo al sistema en su totalidad, sino a cada estación de servicio y a cada uno de los diferentes sub-niveles de una estación de servicio.

¿Cómo aplicar la ley de Little?

Aplicación a toda una estación de servicio:




Aplicación a la cola de una estación de servicio:



Ley de la utilización

$$U_i = \frac{B_i}{T} = \frac{C_i}{T} \frac{B_i}{C_i} = X_i \times S_i \Rightarrow U_i = X_i \times S_i$$

En realidad, se podía haber deducido también a partir de la ley de Little aplicada al servidor de una estación:



$$U_i = \lambda_i \times S_i = X_i \times S_i$$

Ejemplo de aplicación

Como consecuencia de unas medidas sobre el disco duro principal de un servidor de base de datos **no saturado**, sabemos que el tiempo medio de respuesta del disco es 48ms, su tiempo medio de servicio es 30 ms y su productividad 25 trabajos completados por segundo. Calcule el tiempo medio de espera en la cola del disco duro así como el número medio de trabajos en su cola de espera.

- Calcule el tiempo medio de espera en cola del disco duro:

$$W_{disco} = R_{disco} - S_{disco} = 48 - 30 = 18 \text{ ms}$$

- Calcule el número medio de trabajos en su cola de espera:

$$Z_{disco} = N_{disco} - U_{disco} = 1.2 - 0.75 = 0.45 \text{ trabajos}$$

(ley de Little): $N_{disco} = X_{disco} \times R_{disco} = 25 \text{ tr/s} \times 0.048 \text{ s} = 1.2 \text{ trabajos}$

(ley de la Utilización): $U_{disco} = X_{disco} \times S_{disco} = 25 \text{ tr/s} \times 0.03 \text{ s} = 0.75 \text{ trabajos}$
(utilización 75%).

Pregunta: ¿Por qué el tiempo de respuesta (48 ms) es mucho mayor que el tiempo de servicio (30 ms) si la utilización del disco no llega al 100%?

Ley del flujo forzado

Las productividades (flujos) a diferentes niveles del sistema tienen que ser proporcionales a las razones de visita.

La ley del flujo forzado relaciona la productividad del sistema con la de cada uno de los dispositivos que integran el mismo:

$$V_i = \frac{C_i}{C_0} = \frac{X_i}{X_0} \Rightarrow X_i = X_0 \times V_i \quad \textbf{Ley del Flujo Forzado}$$

Como consecuencia de la ley del flujo forzado, las utilizaciones de cada dispositivo también serán proporcionales a la productividad global del sistema, siendo la constante de proporcionalidad precisamente la demanda de servicio del dispositivo:

$$U_i = X_i \times S_i = X_0 \times V_i \times S_i = X_0 \times D_i \quad \textbf{Relación Utilización-Demanda de Servicio}$$

Ejemplo de aplicación II

Un ingeniero informático ha monitorizado un servidor de ayuda a la toma de decisiones durante 24 horas, contabilizando un total de 14400 peticiones externas al servidor. Durante ese tiempo, el monitor *sar* le ha indicado que el procesador ha ejecutado una media de 40 procesos por minuto y que su utilización ha sido del 40%. Suponiendo que el servidor no está saturado, calcule la razón de visita, la demanda de servicio y el tiempo medio de servicio del procesador.

Solución:

Necesitamos calcular primero $X_0 = \lambda_0$ (ya que no saturado) = $14400 \text{ tr} / (24 \text{ hr} \times 60 \text{ min/hr}) = 10 \text{ tr/min}$

$$V_{\text{CPU}} = X_{\text{CPU}} / X_0 = \frac{40 \text{ tr/min}}{10 \text{ tr/min}} = 4$$

$$D_{\text{CPU}} = U_{\text{CPU}} / X_0 = \frac{2.1}{10 \text{ tr/min}} = 0.04 \text{ min} = 2.4 \text{ s}$$

$$S_{\text{CPU}} = D_{\text{CPU}} / V_{\text{CPU}} = 2.4 \text{ s} / 4 = 0.6 \text{ s}$$

Ley general del tiempo de respuesta

Teniendo en cuenta que el número de trabajos dentro de un sistema no es más que la suma del número de trabajos que hay en cada estación de servicio: $N_o = N_1 + N_2 + \dots + N_K$, que $N_i = X_i \times R_i = X_o \times V_i \times R_i$ y que $V_o = 0$, es fácil demostrar que:

$$R_o = V_1 \times R_1 + V_2 \times R_2 + \dots + V_K \times R_K = \sum_{i=1}^K V_i \times R_i$$

expresión conocida como “Ley general del tiempo de respuesta”. Nótese que, en general:

$$R_o \neq R_1 + R_2 + \dots + R_K = \sum_{i=1}^K R_i$$


Ejemplo de aplicación III

Un servidor de ayuda a la toma de decisiones realiza, de media, para cada consulta un total de 12 accesos al disco duro #1 y 30 accesos al disco duro #2. Mediante una herramienta de monitorización, se ha estimado que el tiempo medio de respuesta de ambos discos ha sido de 5 ms. Calcule el tiempo medio que ha tardado el servidor en atender cada consulta:

$$R_0 = \sum_{i=1}^2 V_i \times R_i = V_1 \times R_1 + V_2 \times R_2 = 30 \times 5 + 12 \times 5 = 210 \text{ ms}$$


Nótese que, en este caso:

$$R_0 \neq \sum_{i=1}^2 R_i = R_1 + R_2 = 5 + 5 = 10 \text{ ms}$$

Ley del tiempo de respuesta interactivo

Se obtiene mediante la aplicación de la ley de Little a una red cerrada de tipo interactivo.

N_Z = Número medio de trabajos (=clientes) en reflexión.



$$N_Z = X_0 \times Z; \quad N_0 = X_0 \times R_0$$

$$N_T = N_Z + N_0 = X_0 \times Z + X_0 \times R_0 = X_0 \times (Z + R_0)$$

$$\Rightarrow R_0 = \frac{N_T}{X_0} - Z$$

que se conoce como la *Ley del tiempo de respuesta interactivo*.

Nótese que al ser una red cerrada, el número total de trabajos (=clientes) en la red cerrada ($N_T = N_Z + N_0$), es constante.

Ejemplo de aplicación IV

En un servidor de ficheros, durante un tiempo T , se encuentran conectados un total de 3000 usuarios, cada uno asociado a un único fichero (1 usuario = 1 fichero = 1 trabajo de nuestro modelo). Suponiendo que el tiempo medio de reflexión de cada usuario es de 20 segundos y que el tiempo medio de respuesta del servidor es de 10 segundos por cada fichero, ¿cuál es la productividad del servidor y cuántos trabajos se encuentran, de media, en reflexión?

$$X_0 = \frac{N_T}{R_0 + Z} = \frac{3000}{10 + 20} = 100 \text{ tr/s} \quad N_4 = X_0 \times Z = 2000 \text{ tr}$$

Si se quiere conseguir una productividad de 125 trabajos por segundo, ¿qué tiempo de respuesta debería tener el servidor?

$$R_0 = \frac{N_T}{X_0} - Z = \frac{3000}{125} - 20 = 4 \text{ s}$$

Límites asintóticos del rendimiento

Limitaciones en el rendimiento: cuello de botella


Todo sistema presenta alguna limitación en su rendimiento.

En esta sección veremos que la localización del elemento limitador no solo depende del servidor sino también de la carga.

Además, puede haber más de uno de estos elementos limitadores.

Al elemento limitador del rendimiento del servidor se le denomina cuello de botella (*bottleneck*).

Veremos que la única manera de mejorar las prestaciones de un servidor de manera significativa es actuando sobre el cuello de botella.



Identificación de un cuello de botella

El cuello de botella es el dispositivo con **mayor utilización** ya que será el primero que llegue a saturarse ($U_i=1$) cuando aumente la carga (λ_0 mayor).

$$U_i = X_i \times S_i = X_0 \times V_i \times S_i = X_0 \times D_i = \lambda_0 \times D_i$$

Podemos identificar fácilmente el cuello de botella de un servidor simplemente buscando el dispositivo con **mayor demanda de servicio** ($U_i \propto D_i$).


Si denotamos como “b” al índice del dispositivo cuello de botella, su demanda de servicio y su utilización, vendrán dadas por.

$$D_b = \max_{i=0 \dots K} \{D_i\} = V_b \times S_b$$

$$U_b = \max_{i=0 \dots K} \{U_i\} = X_0 \times D_b$$

Saturación del sistema


El sistema se satura cuando lo hace el cuello de botella ya que, por definición, éste será el primer dispositivo en alcanzar una utilización = 1 cuando aumente la carga.



Operación "normal"

En saturación, el sistema alcanza su productividad máxima:

$$X_0^{max} = 1/D_b$$




Sistema saturado


Sistema equilibrado (*balanced system*)

Sistema en que todos los dispositivos tienen la misma demanda de servicio o utilización (la carga se absorbe equitativamente):


$$U_i \approx U_j \quad \forall i, j = 1 \dots K \quad \longrightarrow \quad D_i \approx D_j \quad \forall i, j = 1 \dots K$$



Todos los dispositivos son cuellos de botella



Aumento de la carga: λ_0 "



Límites asintóticos del rendimiento

Se trata de encontrar una cota superior de la productividad (X_o) e inferior del tiempo de respuesta (R_o) del sistema. Son, por tanto, **límites optimistas** del rendimiento.

¿Cuál es la productividad máxima (X^{max}_0)?

¿Cuál es el tiempo de respuesta mínimo (R^{min}_0)?

Campos de aplicación:

Estudios preliminares: consideración de un gran número de configuraciones candidatas.



Estimación de la mejora potencial de prestaciones que pueden reportar ciertas acciones sobre el sistema.

Planificación de la capacidad (*capacity planning*).





Localización de límites optimistas

Modelos
abiertos



Modelos
cerrados



Límites optimistas: sistemas abiertos

- El valor máximo de la tasa de llegada del sistema, será aquél que sature completamente el dispositivo cuello de botella ($U_b=1$):

$$U_b = X_0 \times D_b = \lambda_0 \times D_b \quad \text{Si } U_b = 1 \Rightarrow \lambda_o^{max} = X_o^{max} = \frac{1}{D_b}$$


A partir de ese momento, una tasa de llegada mayor provocaría la saturación del sistema y, por tanto, dejaría de cumplirse la hipótesis de equilibrio de flujo (X_o ya no podría seguir a λ_o).

- El valor más optimista (= el valor mínimo) del tiempo de respuesta del sistema (R_o^{min}) será el que experimente un trabajo cuando llegue al sistema sin que haya otros trabajos previamente ($W_i = 0 \rightarrow R_i^{min}=S_i \forall i=1..K$):

$$R_o^{min} = \sum_{i=1}^K V_i \times R_i^{min} = \sum_{i=1}^K V_i \times S_i = \sum_{i=1}^K D_i \equiv D$$


Resumen: Límites optimistas en sistemas abiertos

Tiempo de respuesta



$$R_o^{min} = D \equiv \sum_{i=1}^K D_i$$

Productividad



$$X_o^{max} = \frac{1}{D_b}$$

Ejemplo de sistema abierto



Dispositivo	V_i	S_i (ms)	D_i (s)
CPU	16	10	0.16
DISCO A	7	20	0.14
DISCO B	8	30	0.24





- Tiempo de respuesta mínimo:
 - $R_0^{min} = 160 + 140 + 240 = 540 \text{ ms} = 0.54 \text{ s}$
- Productividad máxima:
 - $X_0^{max} = \frac{1}{D_b} = \frac{1}{0.24} = 4.2 \text{ trabj./s}$
- Utilización máxima del disco A:
 - $U_A^{max} = X_0^{max} \times D_A = 0.59$
- Utilización máxima de la CPU:
 - $U_{CPU}^{max} = X_0^{max} \times D_{CPU} = 0.67$
- U_i con $\lambda_0 = 2 \text{ trabajos/s } (=X_0)$
 - $U_{CPU} = X_0 \times D_{CPU} = 0.32$
 - $U_A = X_0 \times D_A = 0.28$
 - $U_B = X_0 \times D_B = 0.48$

Localización de límites optimistas


Modelos
abiertos



Modelos
cerrados



Límites optimistas: sistemas cerrados



Ley de Little a la red completa ($N_T = N_Z + N_O$):

$$N_T = X_0 \times (R_0 + Z)$$

a) Para valores de carga bajos (N_T pequeño):


- Valor optimista del tiempo de respuesta: suponemos que los trabajos siempre encuentran los dispositivos sin ocupar ($W_i = 0 \rightarrow R_i = S_i \quad \forall i=1..K$):

$$R_o \rightarrow R_o^{min} = \sum_{i=1}^K V_i \times R_i^{min} = \sum_{i=1}^K V_i \times S_i = \sum_{i=1}^K D_i \equiv D$$

- Valor optimista de la productividad a partir del valor optimista del tiempo de respuesta:

$$X_0 \rightarrow \frac{N_T}{R_o^{min} + Z} = \frac{N_T}{D + Z}$$

Límites optimistas: sistemas cerrados (II)



Ley de Little a la red completa
($N_T = N_Z + N_o$):

$$N_T = X_o \times (R_o + Z)$$

b) Para valores de carga altos (N_T grande):

- Valor optimista de la productividad. Suponemos que el dispositivo cuello de botella está saturado:


$$U_b = X_o \times D_b \quad \text{Si } U_b \rightarrow 1 \Rightarrow X_o \rightarrow X_o^{max} = \frac{1}{D_b}$$

- Valor optimista del tiempo de respuesta, a partir del valor optimista de la productividad:

$$R_o \rightarrow \left(\frac{N_T}{X_o^{max}} \right) - Z = N_T \times D_b - Z$$


Resumen sistemas cerrados

Tiempo de respuesta



$$R_0 \geq \max\{D, N_T \times D_b - Z\}$$

Productividad



$$X_0 \leq \min\left\{\frac{N_T}{D + Z}, \frac{1}{D_b}\right\}$$

Punto teórico de saturación

Es el valor de N_T en donde las asíntotas coinciden:

$$D = N_T^* \times D_b - Z \Rightarrow N_T^* = \frac{D + Z}{D_b}$$


Propiedades del punto teórico de saturación N_T^* :

Para un número total de trabajos $N_T > N_T^*$, los límites asintóticos vienen impuestos únicamente por el cuello de botella del sistema.

A partir de N_T^* trabajos ya no se puede conseguir el tiempo de respuesta mínimo ya que se empiezan a formar colas de espera en, al menos, el dispositivo cuello de botella.

En principio, es el número ideal de trabajos en la red ya que, al menos teóricamente, para $N_T = N_T^*$ se podría conseguir la productividad máxima y el tiempo de respuesta mínimo del sistema.

Ejemplo de red cerrada





Tiempo de reflexión (Z)		18 s	
Dispositivo	V_i	S_i (s)	D_i (s)
CPU	5	1	5
DISCO A	2	2	4
DISCO B	2	1.5	3

- Asíntotas:

$$R_0 \geq \max\{D, N_T \times D_b - Z\}$$

$$= \max\{12, N_T \times 5 - 18\}$$

$$X_0 \leq \min\left\{\frac{N_T}{D + Z}, \frac{1}{D_b}\right\} = \min\left\{\frac{N_T}{30}, 0.2\right\}$$



- Punto teórico de saturación:

$$N_T^* = \frac{D + Z}{D_b}$$

$$= \frac{12 + 18}{5}$$

$$= 6 \text{ trabajos}$$

Resolución de redes de colas

Algoritmos de resolución de redes de colas

En este apartado vamos a proporcionar una metodología (algoritmo) para resolver modelos de redes de colas. Supondremos conocido:

El número de estaciones de servicio (K).

Por cada estación:

Razón de visita medio de cada estación (V_i).


Tiempo de servicio medio de cada estación (S_i).

Si la red es abierta: Tasa de llegada al sistema (λ_0)

Si la red es cerrada:

Número total de trabajos en la red (N_T).

Si la red es interactiva: Tiempo medio de reflexión de los usuarios (Z).




Hipótesis de partida

Partiremos del peor escenario posible: cuando un trabajo llega a la estación de servicio i -ésima supondremos que:

Tiene que esperar a que se procesen los N_i trabajos que hay en ese momento en la estación (uno sirviéndose y el resto esperando).

Luego, para ser procesado, tendrá que pasar su propio tiempo de servicio.

Por lo tanto, su tiempo de respuesta medio vendrá dado, en el peor de los casos por:



$$R_i = N_i \times S_i + S_i = (N_i + 1) \times S_i$$


De donde se deduce que:

$$R_i = (X_i \times R_i + 1) \times S_i \Rightarrow$$

$$R_i = \frac{S_i}{1 - X_i \times S_i} = \frac{S_i}{1 - U_i} = \frac{S_i}{1 - X_{\cdot} \times D_i}$$

Resolución de redes abiertas

Modelos abiertos (suponemos conocidos: λ_o, V_i y $S_i \forall i=1..K$).



$D_i = V_i \times S_i$ ← Demanda de servicio de cada estación

$R_i = \frac{S_i}{1 - X_0 \times D_i} = \frac{S_i}{1 - \lambda_0 \times D_i}$ ← Tiempo de respuesta de cada estación

$R_0 = \sum_{i=1}^K V_i \times R_i = \sum_{i=1}^K \frac{V_i \times S_i}{1 - \lambda_0 \times D_i} = \sum_{i=1}^K \frac{D_i}{1 - \lambda_0 \times D_i}$ ← Tiempo de respuesta del sistema

El resto de variables operacionales se pueden calcular usando sus expresiones habituales ($U_i, X_i, N_i, W_i, Q_i, \dots$).



Ejemplo: resolución de redes abiertas

Recurso	V_i	S_i (s)	D_i (s)
CPU	9	0.010	0.09
DISCO	3	0.020	0.06
RED	5	0.016	0.08

Como ya sabíamos, hay un valor límite:

$$\lambda_0^{max} = X_0^{max} = 1/D_b = 11.1 \text{ trabajos/s}$$

A partir de ahí, el sistema se satura y ya no se mantiene el equilibrio de flujo: $X_0 \neq \lambda_0$



Resolución con solvenet

Programa muy sencillo que resuelve redes de colas utilizando los algoritmos de esta sección.

Disponible el código fuente en lenguaje C (moodle).

Los parámetros del modelo se indican en la línea de comandos.

```
Usage: solvenet [0|1] [lambda0| NT Z] K S1 V1...SK VK
  With no parameters, shows this message
  network: 0 (open) and 1 (closed)
  lambda0: arrival rate = throughput (only open networks)
  NT:      total number of jobs in the net (only closed nets)
  Z:      think time (only interactive closed networks)
  K:      number of service stations
  Si:     service time of device i
  Vi:     ratio visit of device i
```

Resolución con solvenet: redes abiertas

Recurso	V_i	S_i (s)	D_i (s)
CPU	9	0.010	0.09
DISCO	3	0.020	0.06
RED	5	0.016	0.08

λ_o	5.0 trabajos/s
-------------	----------------

solvenet 0 5.0 3 0.01 9 0.02 3 0.016 5



```

*****
*   NAME   *   Ui   *   Ni   *   Ri   *   Xi   *
*****
*
*
* DEV 1    *   0.4500*   0.8182   0.0182*   45.0000*
*
*
*
* DEV 2    *   0.3000*   0.4286*   0.0286*   15.0000*
*
*
*
* DEV 3    *   0.4000*   0.6667*   0.0267*   25.0000*
*****

```

Resolución con solvenet: redes abiertas (II)

Recurso	V_i	S_i (s)	D_i (s)
CPU	9	0.010	0.09
DISCO	3	0.020	0.06
RED	5	0.016	0.08

λ_o	5.0 trabajos/s
-------------	----------------

solvenet 0 5.0 3 0.01 9 0.02 3 0.016 5



```

*****
*   NAME   *   Vi   *   Si   *   Di   *   Qi   *
*****
*
*   DEV 1   *   9.0000*   0.0100   0.0900   0.3682*
*           *           *           *
*
*   DEV 2   *   3.0000*   0.0200*   0.0600*   0.1286*
*           *           *           *
*
*   DEV 3   *   5.0000*   0.0160*   0.0800*   0.2667*
*****

```

Tema 6

Resolución con solvenet: redes abiertas (III)

Recurso	V_i	S_i (s)	D_i (s)
CPU	9	0.010	0.09
DISCO	3	0.020	0.06
RED	5	0.016	0.08

λ_o	5.0 trabajos/s
-------------	----------------

```
solvenet 0 5.0 3 0.01 9 0.02 3 0.016 5
```



```
*****
*          ASIMPTOTIC BOUNDS          *
*****
*                                     *
* R0_min =          0.2300            *
* X0_max =          11.1111           *
*                                     *
*****
```

```
*****
*          SYSTEM VARIABLES            *
*****
*                                     *
* #JOBS IN SYSTEM (N0)                * 1.9134*
*                                     *
* RESPONSE TIME (R0)                  * 0.3827*
* MINIMUM RESPONSE TIME                * 0.2300*
*                                     *
* THROUGHPUT (X0)                     * 5.0000*
* MAXIMUM THROUGHPUT                   * 11.111*
*                                     *
*****
```

Resolución de redes cerradas

Modelos cerrados (suponemos conocidos: N_T , Z y V_i, S_i)

Debemos ir resolviendo la red para valores incrementales del número de trabajos en la red hasta alcanzar N_T : $n_T = 0, 1, \dots, N_T$.

Notación: $N_i(n_T)$: Número de trabajos en la estación de servicio i si en la red hubiese n_T trabajos. Ídem para los tiempos de respuesta $R_i(n_T)$ y las productividades $X_i(n_T)$.

For $i = 1$ *to* K *do* $N_i(0) = 0$ ← Inicialización de trabajos en las de estaciones.

For $n_T = 1$ *to* N_T *do*

For $i = 1$ *to* K *do* $R_i(n_T) = (N_i(n_T - 1) + 1) \times S_i$ ← Tiempo de respuesta de cada estación.


$R_6(n_T) = 7 \quad V_i \times R_i(n_T), \quad X_6(n_T) = \frac{n_T}{Z + R_6(n_T)}$ ← Tiempo de respuesta y productividad del sistema.

For $i = 1$ *to* K *do* $N_i(n_T) = X_6(n_T) \times V_i \times R_i(n_T)$

← Actualización del número de trabajos en cada estación.

Ejemplo: resolución de redes cerradas

T. reflexión (Z)	2 s	
Recurso	V_i	S_i (s)
CPU	10	0.01
DISCO1	5	0.02
DISCO2	4	0.03



$$N_{CPU}(0) = N_{DISC01}(0) = N_{DISC02}(0) = 0$$

$$n_T = 1$$

$$R_{CPU}(1) = S_{CPU} = 0.01s$$

$$R_{DISC01}(1) = S_{DISC01} = 0.02s$$

$$R_{DISC02}(1) = S_{DISC02} = 0.03s$$

$$R_6(1) = 10 \times 0.01 + 5 \times 0.02 + 4 \times 0.03 = 0.32s$$

$$X_6(1) = \frac{1}{2 + 0.32} = 0.43 \text{ traba@os/s}$$

$$N_{CPU}(1) = 0.43 \times 10 \times 0.01 = 0.043$$

$$N_{DISC01}(1) = 0.43 \times 5 \times 0.02 = 0.043$$

$$N_{DISC02}(1) = 0.43 \times 4 \times 0.03 = 0.052$$

Ejemplo: resolución de redes cerradas (II)

$$N_{CPU}(1) = 0.043; N_{DISCO1}(1) = 0.043; N_{DISCO2}(1) = 0.052$$

$$n_T = 2$$

$$R_{CPU}(2) = (0.043 + 1) \times S_{CPU} = 0.01043s$$

$$R_{DISCO1}(2) = (0.043 + 1) \times S_{DISCO1} = 0.0209s$$

$$R_{DISCO2}(2) = (0.052 + 1) \times S_{DISCO2} = 0.0316s$$

$$R_0(2) = \sum_{i=1}^3 V_i \times R_i(2) = 0.3348s$$



$$X_0(2) = \frac{2}{2 + 0.3348} = 0.857 \text{ trabajos/s}$$

$$N_{CPU}(2) = 0.857 \times 10 \times 0.01043 = 0.0894$$

$$N_{DISCO1}(2) = 0.857 \times 5 \times 0.0209 = 0.0894$$

$$N_{DISCO1}(2) = 0.857 \times 4 \times 0.03348 = 0.1081$$

etc. hasta llegar al valor $n_t = N_T$ que nos pidan



Resolución con solvenet: redes cerradas

Recurso	V_i	S_i (s)
CPU	10	0.01
DISCO1	5	0.02
DISCO2	4	0.03

T. reflexión (Z)	2 s
Nº Trabajos en la red cerrada (N_T)	2

solvenet 1 2 2 3 0.01 10 0.02 5 0.03 4



```

*****
*   NAME   *   Ui   *   Ni   *   Ri   *   Xi   *
*****
*          *          *          *          *
* DEV 1    * 0.0857* 0.0894 0.0104 8.5659*
*          *          *          *
*          *          *          *
* DEV 2    * 0.0857* 0.0894* 0.0209* 4.2830*
*          *          *          *
*          *          *          *
* DEV 3    * 0.1028* 0.1081* 0.0316* 3.4264*

```


Tema 6

Resolución con solvenet: redes cerradas (II)

Recurso	V_i	S_i (s)
CPU	10	0.01
DISCO1	5	0.02
DISCO2	4	0.03

T. reflexión (Z)	2 s
Nº Trabajos en la red cerrada (N_T)	2

```
solvenet 1 2 2 3 0.01 10 0.02 5 0.03 4
```



```
*****
*   NAME   *   Vi   *   Si   *   Di   *   Qi   *
*****
*          *          *          *          *
*   DEV 1   * 10.0000* 0.0100   0.1000   0.0037*
*          *          *          *          *
*   DEV 2   *  5.0000* 0.0200   0.1000   0.0037*
*          *          *          *          *
*   DEV 3   *  4.0000* 0.0300   0.1200   0.0053*
```

©José Manuel Soto Hidalgo

Tema 6

Resolución con solvenet: redes cerradas (III)

Recurso	V_i	S_i (s)
CPU	10	0.01
DISCO1	5	0.02
DISCO2	4	0.03

T. reflexión (Z)	2 s
Nº Trabajos en la red cerrada (N_T)	2

solvenet 1 2 2 3 0.01 10 0.02 5 0.03 4



```

*****
*           SYSTEM VARIABLES           *
*****
*                                     *
*                                     *
* #JOBS IN SYSTEM (N0)               * 0.2868*
* #INTERACTIVE USERS (NZ)            * 1.7132*
* #JOBS IN THE NET (NT)              * 2*
* SATURATION POINT (N*)              * 20*
*                                     *
* RESPONSE TIME (R0)                 * 0.3348*
* MINIMUM RESPONSE TIME              * 0.3200*
*                                     *
* THROUGHPUT (X0)                   * 0.8566*
* MAXIMUM THROUGHPUT                 * 8.3333*
*                                     *

```

```

*****
*           ASIMPTOTIC BOUNDS          *
*****
*                                     *
* R0_min = max {0.32, 0.12*NT-2.00}*
*                                     *
* X0_max = min {NT/2.32, 8.33}        *
*                                     *
*                                     *
*****

```


Técnicas de mejora

Técnicas para mejorar las prestaciones

Para mejorar las prestaciones de manera significativa hay que actuar sobre el cuello de botella del sistema.

Actualización o reposición (upgrading).

Sintonización o ajuste (tuning).



Actualización o reposición (*upgrading*)

Remplazar dispositivos por otros más rápidos.

Procesador, memoria, placa base, disco...


Añadir dispositivos para poder realizar más tareas en paralelo.

Ejemplo: multiprocesadores, matrices de discos (RAID)...

Algunos problemas

Compatibilidad de los nuevos elementos con los existentes.

Facilidad del sistema para dejarse actualizar.



Sintonización o ajuste (*tuning*)

Optimización del funcionamiento de todos los componentes existentes:

Componentes hardware.

Sistema operativo.

Aplicaciones.

Muchos ajustes se hacen en el sistema operativo:


Políticas de gestión de procesos y memoria virtual.

Distribución de la información entre discos.

Algunos problemas:



Hay que conocer muy bien el sistema operativo y el funcionamiento de los componentes hardware.

Posible alteración de la fiabilidad.



Ejemplo: sistema abierto (servidor web)

Dispositivo	V_i	S_i (s)	D_i (s)
CPU	10	0.02	0.2
DISCO A	4	0.02	0.08
DISCO B	5	0.01	0.05





$$R_0^{\min} = 0.33 \text{ s} \quad X_0^{\max} = \frac{1}{D_b} = \frac{1}{0.2} = 5.0 \text{ pet/s}$$

Actualización: CPU doble de rápida

Dispositivo	V _i	S _i (s)	D _i (s)
CPU	10	0.01	0.1
DISCO A	4	0.02	0.08
DISCO B	5	0.01	0.05

La CPU se mantiene como cuello de botella pero con menor demanda




$$R_0^{\min} = 0.23 \text{ s} \quad X_0^{\max} = \frac{1}{D_b} = \frac{1}{0.1} = 10.0 \text{ pet/s}$$

Actualización: discos doble de rápidos

Dispositivo	V_i	S_i (s)	D_i (s)
CPU	10	0.02	0.2
DISCO A	4	0.01	0.04
DISCO B	5	0.005	0.025


La CPU se mantiene como cuello de botella pero con la misma demanda



$$R_0^{\min} = 0.265 \text{ s} \quad X_0^{\max} = \frac{1}{D_b} = \frac{1}{0.2} = 5.0 \text{ pet/s}$$

Ejemplo: sistema cerrado interactivo (servidor de ficheros)



Tiempo de reflexión (Z)		4 s	
Dispositivo	V _i	S _i (s)	D _i (s)
CPU	10	0.02	0.2
DISCO A	4	0.02	0.08
DISCO B	5	0.01	0.05



$$R_0^{min} = \max\{D, N_T \times D_b - Z\} = \max\{0.33, N_T \times 0.2 - 4\}$$

$$X_0^{max} = \min\left\{\frac{N_T}{D + Z}, \frac{1}{D_b}\right\} = \min\left\{\frac{N_T}{4.33}, 5\right\}$$

Rendimiento del sistema original





Punto teórico de saturación:

$$N_T^* = \left\lceil \frac{D + Z}{D_b} \right\rceil = 22 \text{ trabajos}$$

Los valores óptimos de ambos índices están determinados por el cuello de botella (CPU)

Actualización: CPU doble de rápida



Punto teórico
de saturación:

$$N_T^* = \left\lceil \frac{D + Z}{D_b} \right\rceil$$

= 43 trabajos

Asíntotas:

$$R_0^{min} = \max\{D, N_T \times D_b - Z\} = \max\{0.23, 0.1 \times N_T - 4\}$$

$$X_0^{max} = \min\left\{\frac{N_T}{D + Z}, \frac{1}{D_b}\right\} = \min\left\{\frac{N_T}{4.23}, 10\right\}$$