

TEORÍA CESI

TEMA 1

Un **sistema informático** es el conjunto de hardware, software y humanware que permite almacenar y procesar información.

Se clasifican:

- **Según el nivel de paralelismo:**
 - **SISD:** Un procesador ejecuta un solo flujo de instrucciones de una sola memoria
 - **SIMD:** Se aplica la misma operación en un conjunto de datos, con varias unidades de procesamiento.
 - **MISD:** Muchas unidades realizan operaciones en los mismos datos, (redes neuronales)
 - **MIMD:** Procesadores asíncronos y autónomos que ejecutan operaciones sobre cualquier dato
- **Según su uso:**
 - **Uso general (PC)**
 - **Uso específico:** tiene una función concreta.
 - **Sistemas empotrados:** Sistema dentro de otro sistema que realiza funciones específicas para el dispositivo en el que se encuentra
 - **Servidores:** Forman parte de una red y proporcionan servicios a clientes, pudiendo ser o no dedicados (usan toda su potencia para atender solicitudes). Se puede crear **computación de alto rendimiento**, donde las peticiones se distribuyen entre servidores por unos nodos balanceadores dependiendo del tráfico.
- **Según su arquitectura:**
 - **Sistema aislado:** no interactúa con otros sistemas.
 - **Cliente-servidor:** las tareas se reparten entre proveedores de recursos y clientes.
 - **N capas:** cliente-servidor con n tipos de nodos, siendo más escalable y aliviando carga de los servidores.
 - **Cliente-cola-cliente:** los nodos son ahora clientes y el servidor es una cola que captura las peticiones.

Fundamentos de configuración de un SI:

- **Disponibilidad:** Que el sistema esté funcionando y disponible. Se comprueba el tiempo de inactividad.
- **Tolerancia a fallos:** Que el sistema sea capaz de soportar fallos inesperados, comprobando tiempo medio entre fallos.
- **Fiabilidad:** Si desarrolla su actividad sin presencia de errores.
- **Seguridad:** que sea seguro ante accesos no autorizados, corrupción de datos, etc. (cortafuegos, encriptación)

- **Escalabilidad:** Si puede crecer en tamaño y funcionamiento a mayor carga se le ofrezca. Se usa virtualización. Puede ser **vertical** (aumentar recursos locales) u **horizontal** (replicar el sistema en otras máquinas).
- **Mantenimiento:** Comprobación del correcto funcionamiento del sistema, y que los drivers y el SO sean fáciles de actualizar.
- **Coste:** que sea asequible y se ajuste al presupuesto.
- **Eficiencia energética:** tecnologías verdes para consumir menos energía y calor.

Se **evalúa un SI** comprobando cómo el software usa el hardware con unos índices de **rendimiento** (velocidad para realizar una determinada carga) para optimizar diseños y predecir la **carga** (tareas que ha de realizar el sistema y toma recursos del mismo) aceptable. Normalmente la carga y el rendimiento son inversamente proporcionales.

La **carga se verá afectada** por programas simultáneos y accesos a servidores, mientras que **para el rendimiento** será la calidad del software y el SO y la distribución de la carga. **Para incrementar el rendimiento** se afinan elementos del SO o se añaden o se reemplazan unidades, aunque por más que mejores un componente, no podrás mejorar el tiempo de respuesta más que el tiempo en el que usas dicho componente. **Para medirlo**, se toma el tiempo de respuesta (desde el inicio hasta el final) y la productividad (cantidad de trabajo realizado por unidad de tiempo). Si divides los rendimientos de dos sistemas consigues la **ganancia** de uno sobre otro. También puedes obtener la ganancia G de un sistema al mejorar un componente k veces y que se use un tiempo f (esto solo sirve para una única carga) con la **Ley de Amdahl**: $G = 1/[(1 - f) + (f/k)]$. Para un k infinito, el sistema será a lo sumo 2.5 veces (o un 150%) más rápido.


TEMA 2

Carcasa: la torre. Antes se usaba AT, ahora ATX.

Placa base: tarjeta principal de circuito impreso. A ella se conectan los componentes del computador y contiene diversos conectores para los periféricos. Están hechas de láminas de cobre rodeadas de otras láminas no conductoras. A día de hoy son multicapa.

- Los **zócalos de la CPU** facilitan la conexión entre el microprocesador y la placa base. Permite reemplazar el microprocesador sin soldaduras.
- Los **zócalos de la memoria RAM** son en los que se insertan los módulos de la memoria principal. Vienen agrupados en canales de memoria, y la CPU puede acceder a ellos en paralelo.
- Los **zócalos de expansión** están sobre la placa base y permiten la conexión con otras tarjetas de circuito impreso.
- El **conector SATA** es un bus serie full duplex de 7 pines que permite una velocidad de transferencia de hasta 6Gbps en los SATA 3.
- El **interface P-ATA** tiene 40 patillas y un bus paralelo, y una velocidad máxima de transferencia de hasta 133MBps.
- **Fuente de alimentación:** busca obtener las tensiones continuas que necesita el ordenador. Es de tipo FA conmutada y tiene una potencia de unos 250-1000W
- **Otros conectores:**

Conectores del Panel Trasero



ITEM		ITEM	
1, 19	PS / 2 ratón (verde) – teclado (violeta)	10	Puerto antena Wireless
2	Puerto Paralelo (DB25)	11, 12, 13	USB 2.0
3, 4, 5, 6, 15, 14	Audio (hasta 8 canales) Trasero, central, subwoofer, micro, entrada.	16	Puerto External SATA
7, 8	LAN (RJ45)	17	Salida óptica audio digital
9	Led Wireless	18	Salida coaxial audio digital

- **Firewire:** es un puerto serie de altas prestaciones con 6 patillas full duplex.
- **Chipset:** conjunto de circuitos integrados encargados de controlar las comunicaciones entre los diferentes componentes de la placa base.
 - **El puente norte** se encarga de la comunicación entre el microprocesador, RAM y tarjeta gráfica. Depende de la arquitectura.
 - **El puente sur** se encarga de la comunicación entre el puente norte y el resto de periféricos de menores exigencias.
- **BIOS:** para chequear el arranque y guardar la configuración básica del sistema. Para los primeros ordenadores eran una ROM, pero ahora la BIOS es programable. Ahora se usan memorias flash para guardar la BIOS.

Ley de Moore: el número de transistores en un chip se duplica cada dos años.

Procesador: tiene una CPU multinúcleo de 2 o 4 cores. Los de Intel y AMD traen GPU integrada en algunas versiones.

Disipación térmica: El ordenador se acabará calentando por su uso continuado. Algunas piezas pueden desenchajarse o soltarse. Para contrarrestar esto se usa la pasta térmica.

Memorias:

- RAM: acceso aleatorio
- ROM: solo lectura
- SRAM: estáticas
- DRAM: dinámicas
- PROM: ROMs programables
- EEPROM: se pueden grabar y borrar con 5V
- RAM dinámica: hay que refrescarla cada cierto tiempo.
- FLASH: mayor velocidad y capacidad pero se estropean con el uso

Un problema que surge es la necesidad de aumentar el ancho de banda de la memoria. Se suelen usar tecnologías de alta velocidad, organizar la memoria de forma jerárquica o incrementar el ancho del bus de la memoria.

Dispositivos E/S: Discos duros, SSDs, PATA, SATA, SCSI.

Un **sistema operativo** es un programa o conjunto de estos que gestiona los recursos del hardware y provee servicios a los programas de aplicación. Entre sus componentes están el gestor de recursos, el sistema de archivos, protección y comunicaciones y los programas del sistema.

TEMA 3

Cuanto más potentes son los servidores menos porcentaje se usa de ellos, además de que son más caros y necesitan más energía. Existen **tres formatos de servidores** diferentes:

- **Torre**: como los ordenadores de los 2000.
- **Blade**: servidores integrados al máximo, para sistemas de altas prestaciones.
- **Rack**: el formato más utilizado de servidor, se almacena en armarios.

Para los armarios, se puede hacer **cableado horizontal** (del armario a la toma) y **vertical** (entre armarios). Además existen SO para servidores, dando servicios sin necesidad de instalar software de terceros, con herramientas de administración y con prestaciones para servicios importantes como FTP o SSH.

La **virtualización** proyecta un subconjunto de recursos y servicios del sistema origen hacia otro de forma que sólo ese conjunto sea visible para el mismo. Se utiliza una interfaz de uso. Permite particionar el hardware para crear máquinas virtuales con subsistemas independientes, pero las instrucciones inocuas se llevan a cabo en el hardware real y los programas virtuales sólo pueden consumir recursos del subsistema. Algunas **ventajas de la virtualización** son la facilidad para desplegar sistemas, la eficiencia (es escalable), el poder tener varios SOs en un mismo equipo, y que si el subsistema falla, el origen no.

Para virtualizar, además de un sistema, se necesita una capa de virtualización entre el SO y la máquina virtual (hipervisor). El hardware físico se mapea en recursos virtuales para que lo usen las máquinas. A diferencia de la virtualización, la **emulación** reproduce fielmente la interfaz y el comportamiento del hardware.

Las **características de la virtualización** son:

- **Encapsulación**: Tienes una representación de una máquina física en otra
- **Particionamiento**: el anfitrión se puede dividir en particiones para ser ejecutadas en diferentes máquinas virtuales
- **Aislamiento**: si la máquina falla, el resto y el sistema físico no se ven afectados.

Tipos de virtualización:

- **Virtualización de plataformas**: se separa un SO de los recursos de la plataforma.
 - **Virtualización nativa o completa**: muchas instancias de un SO no modificado funcionan a la vez.
 - **Para-virtualización**: no se emula el hardware, sino una serie de APIs a un SO conveniente para utilizarlas.
 - **Virtualización a nivel de SO**: las máquinas comparten el mismo kernel del host y se crean diferentes instancias.
 - **Virtualización de aplicaciones**: entorno virtualizado con todo lo necesario para ejecutar la aplicación sobre un servidor o un cliente.
- **Virtualización de recursos**: sólo se virtualiza la memoria y/o almacenamiento. Tienes memoria virtual, almacenamiento NAS y SAN.

Un **centro de procesamiento de datos** es donde se concentran los recursos para dicha tarea. Se componen de:

- **Armarios** (racks o blades).
- Una **infraestructura** de suelos y techos falsos para refrigerar y tener una más sencilla instalación, así como pintura ignífuga, y un cableado con líneas redundantes y apartado de los cables de corriente.
- El **sistema de alimentación** suele venir con SAls por si se fuera la luz y el **sistema anti-incendios** usa gases como CO2 o halón.

Para ubicar un CPD se toma en cuenta que el lugar en sí no tenga interferencias, inundaciones ni vibraciones; que las salas no tengan ventanas y estén bien climatizadas, y que además de los sistemas de prevención, se tenga una política de acceso estricta. Parte de estos recursos pueden ser ofrecidos por demanda a un cliente (**modelo cloud**).

TEMA 4

Un **monitor de actividad** se encarga de analizar la carga de un sistema mientras se usa, comprobando memoria utilizada, acceso a dispositivos, número de procesos, interrupciones y fallos, etc. Tiene una **interfaz**, un **selector**, un **procesador** de la información, un **grabador** de la información y un **intérprete** (a veces gráfico). Esto permite al administrador saber el uso de recursos, al ingeniero predecir cargas futuras, al programador conocer las partes críticas y al sistema para adaptarse. Se mide cada cierto tiempo o cuando ocurre un evento.

Existen monitores **hardware** (temperatura de CPU), **software** (la mayoría) o **híbridos**. Si tienen interacción, pueden ser de tipo **batch** (guardan la info) u **online** (puedes interactuar con él).

Atributos del monitor:

- **Exactitud:** diferencia entre el valor real y el valor que está midiendo el monitor
- **Precisión:** dispersión de la medida
- **Resolución:** cuánto tiene que cambiar el valor a medir para detectar un cambio
- **Frecuencias de muestreo:** cada cuánto tiempo tomamos la medida
- **Tasa de entrada:** frecuencia máxima de ocurrencia de los eventos que el monitor puede observar
- **Anchura:** cuantos bits de información se almacena por cada medida del monitor
- **Sobrecarga:** cuánto tiempo le roba el monitor al sistema. Uso del recurso / capacidad total del recurso (no pasarse para no perturbar el funcionamiento)

MONITORIZACIÓN A NIVEL DE SISTEMA

- **/proc:** directorio en RAM usado por el kernel Unix como interfaz con sus estructuras internas. Fuente principal de información para monitores de Linux.
- **Uptime:** tiempo de actividad del sistema y carga media (normalmente < 3)

1:21pm	up	1 day,	4:09, 18 users,	load average: 1.04, 0.30, 0.09
				
Hora actual	Tiempo en marcha	Procesos a corto, medio y largo plazo (1, 5, 15 min)		

- **Carga del sistema:** número de procesos en estado running, runnable o I/O blocked

- [Los **estados básicos de un proceso** son en **ejecución o listo** (running/runnable), **esperando E/S** (I/O blocked) o **bloqueado esperando evento de usuario**]
- **Comandos:**
 - **ps**: lista procesos y sus estados.
 - **top**: carga media, procesos y uso de memoria en tiempo real.
 - **vmstat**: CPU, memoria virtual, acceso a disco y procesos bloqueados.
 - **who / w**: usuarios conectados y su actividad.
 - **df**: espacio libre en disco.
 - **du**: espacio ocupado por archivos.
 - **hdparm**: parámetros del disco.
- **SysStat**: Herramientas como mpstat e iostat para monitorizar CPU y E/S.
- **SAR (System Activity Reporter)**: Monitor ampliamente usado para detectar cuellos de botella. Muestra datos actuales e históricos usando información de /proc y /dev/mem. Basado en sadc (recoge y guarda datos en binario) y sar (convierte a texto). Funcionamiento batch; los datos se almacenan en ficheros saDD (día del mes). Se ejecuta periódicamente mediante cron (ej. cada 5 min = 288 veces/día). Sarcheck presenta los resultados en HTML usando gnuplot

-rw-r--r--	1 root	root	3049952	Oct 7 23:55	sa07
-rw-r--r--	1 root	root	2372320	Oct 8 18:45	sa08
actual  día					

MONITORIZACIÓN A NIVEL DE APLICACIÓN

Se busca obtener información sobre un programa en funcionamiento (cuánto tarda, cuánto se ejecuta cada línea...) para optimizar su código. Se usa un **profiler**, con el cual se toma el programa original, se añaden librerías de recogida de información y se ejecuta con estas (esto añade un poco más de peso y posiblemente tiempo al programa que el original).

Time mide, de un programa, el **tiempo usado por el sistema**, el **tiempo que usa la cpu en modo usuario** y el **tiempo que la cpu ha estado en modo kernel**. Nunca sumarán el total porque otros programas se pueden meter entre ciclos de cpu o tendrá E/S.

/usr/bin/time es más específico, mostrando los cambios de contexto (in)voluntarios.

Gprof se usa con gcc y te dice cuánto dura cada llamada a función y cuántas veces se ejecuta por programa.

Gcov informa de cómo se ha ejecutado línea a línea cada programa.

TEMA 5

Características de un buen índice de rendimiento de un sistema:

- **Representatividad y fiabilidad**: si un sistema es mejor que otro, el índice de rendimiento debe mostrarlo.
- **Linealidad**: si cambia el rendimiento, el índice debe cambiar proporcionalmente.

- **Repetibilidad:** si en las mismas circunstancias hago la misma prueba, deben salir los mismos resultados.
- **Fácil de medir y consistente:** se debe medir de igual forma en todas las circunstancias

Índices más comunes:

- **MIPS nativos:** millones de instrucciones por segundo, son dependientes del programa y se miden en una máquina concreta para un programa concreto.
- **MIPS relativos:** consiste en poner los MIPS referenciados a una máquina de referencia. Cuánto tiempo tarda más en tu ordenador que en una máquina de referencia.
- **MFLOPS:** millones de operaciones en coma flotante por segundo, sirve para cargas intensivas en cálculo. Cambia entre arquitecturas.
- **MFLOPS normalizados:** en los que las operaciones más sencillas cuentan como 1, divisiones cuentan como 4 y las más complicadas (trigonómicas) cuentan como 8. Multiplicar cada operación por el peso que tienen.

Para recrear la carga real del sistema se pueden crear **modelos personalizados** (difíciles de extrapolar) o **modelos genéricos** (similar a la que queremos reproducir). También podemos tomar un **benchmark** (un conjunto de programas diseñado con el fin de comparar algunas características de rendimiento entre equipos). De estos hay tres:

- **Microbenchmarks o de componentes:** estresan componentes específicos.
- **De sistema completo:** estresan todo el sistema, lista de programas que se ejecutan.
- **Específicamente para el usuario.**

Un benchmark consiste en un conjunto de pruebas, ya que el rendimiento es multidimensional.

Para comparar resultados se suelen usar medias:

- **aritmética,** fácil de interpretar y basada en el tiempo medio de ejecución
- **ponderada,** que asigna pesos según la importancia de cada prueba y suele expresarse como ratios respecto a una máquina de referencia, aunque puede sesgar los resultados
- **geométrica,** independiente de la máquina de referencia y que mantiene el orden relativo entre sistemas, favoreciendo mejoras grandes frente a empeoramientos leves.

En cualquier caso, se debe verificar que las diferencias sean estadísticamente significativas.

Una **distribución normal** es aquella en la que el 95% de los valores están entre ± 2 varianzas.

El **teorema central del límite** establece que la distribución de las medias muestrales tiende a una normal al aumentar el tamaño de la muestra. Cuando la desviación típica de la población es desconocida y el tamaño muestral es pequeño, se utiliza la distribución t de Student, que es similar a la normal pero con colas más largas. La t depende de los **$n - 1$ grados de libertad**, ya que la media muestral fija una restricción y solo $n - 1$ valores son independientes. A medida que n crece, la t de Student converge a la normal.

Se puede comprobar si la diferencia entre máquinas es significativa o no mediante:

- **Intervalos de confianza:** Para poder estar $1-\alpha\%$ seguros de que los rendimientos son similares, el estadístico de la t de student debe situarse en el intervalo $[-t_{\alpha/2}, t_{\alpha/2}]$. Este es el intervalo de confianza, y para un 95% de confianza ($\alpha = 0.05$), el intervalo es $[-t_{0,025}, t_{0,025}]$. Debes buscar en la tabla considerando los grados de libertad.
- **Intervalo de la media real:** Revisar el posible intervalo de valores que puede tomar la media, según el alpha que hayamos elegido. Con una confianza del $1-\alpha\%$, la media estará comprendida entre $t_{\alpha/2}$ veces la desviación típica muestral, teniendo como

centro la media muestral. Si en ese intervalo de posibles medias no está el 0, las diferencias son significativas, ya que no es posible que las medias salgan iguales y los dispositivos sean iguales.

- **Test del p-valor:** El p-valor se puede explicar como la probabilidad de que el estadístico pueda salir aún más extremo de lo que te ha salido. Si ha salido 3, es la probabilidad de que el valor absoluto de t sea igual o superior a 3. Si la probabilidad es baja, es porque el estadístico es muy extremo. Si el p valor es menor que α , nuestra hipótesis queda refutada de forma fulminante, ya que está fuera del $1-\alpha\%$ central de la campana. Por ejemplo, si el p-valor es 0,03, significa que la probabilidad de que nos salga un estadístico igual o superior es del 3%, que está fuera de lo que abarca nuestra alfa de 0,05, un 95% de confianza (y del espacio de la campana). $0,03 < 0,05$, así que se concluye que las diferencias son significativas.

TEMA 6

Un **modelo** es una abstracción del SI real, compuesto de dispositivos (procesador, memoria) y trabajos que los usan (programas, peticiones). Existen **modelos basados en redes de colas** para ver los tiempos de respuesta para un trabajo y ver los cuellos de botella. En estos modelos encontramos **estaciones de servicio**, objetos abstractos compuestos de un dispositivo y una cola, donde los trabajos esperan a que se libere el dispositivo. Dentro de esta estación están las **variables**:

- W (tiempo de espera en cola)
- S (tiempo de servicio, uso del recurso)
- R (tiempo de respuesta de la estación de servicio $\rightarrow R = W + S$).

Pueden haber estaciones con más de un servidor o con infinitos servidores (donde $W = 0$).

Para modelar el tiempo que tarda el usuario en responder con otra petición, se añade una variable Z de tiempo de reflexión.

Se pueden conectar estaciones creando una **red de colas**. De estas, puede haber:

- **abiertas**, donde los trabajos entran, se realizan, y terminan saliendo por un sumidero.
 - N (nº trabajos) puede variar
 - Partimos de una tasa de llegada de trabajos λ
 - Objetivo: calcular R y N dentro del sistema
- **Cerradas**, donde N es fijo, sin fuentes ni sumideros
 - Objetivo: calcular R y productividad media, X.
 - Pueden ser de tipo **batch** (cargas por lotes) o **interactivos** (hay Z).
- **Mixtas**, complicadas pero realistas.

En un **modelo de servidor central**, el programa entra al sistema (CPU), y sale del todo o va al módulo de E/S para volver. Si pasa n veces por la CPU, pasa n-1 por E/S.

OPERACIONES VARIAS:

- T: duración del periodo de medida. Es global.
- A_i : número de trabajos que llegan al dispositivo (la estación de servicio) i.
- C_i : número de trabajos completados por el dispositivo i.
- B_i : tiempo que el dispositivo i está ocupado.
- λ_i : tasa de llegada de trabajos al dispositivo i $\rightarrow A_i / T$
- X_i : productividad media del dispositivo i $\rightarrow C_i / T$

- S_i : tiempo de servicio, el uso del recurso i . (segundos/trabajo) $\rightarrow B_i / C_i$
- W_i : tiempo de espera en cola del dispositivo i . (segundos/trabajo)
- R_i : tiempo de respuesta medio del dispositivo i . (segundos/trabajo) $\rightarrow W_i + S_i$
- τ_i : tiempo entre llegadas al dispositivo i . La inversa de la tasa de llegada.
- U_i : utilización. Porcentaje de tiempo que ha estado en uso con respecto al tiempo total. Es adimensional. Número medio de trabajos servidos por el dispositivo $\rightarrow B_i / T$
- Q_i : número medio de trabajos en espera en cola por unidad de tiempo.
- N_i : número medio de trabajos en la estación de servicio i (tanto en cola como en el recurso) por unidad de tiempo $\rightarrow Q_i + U_i$
- V_i : razón de visita. Proporción entre trabajos completados por el sistema y completados por el dispositivo, de donde se saca que el trabajo ha pasado V_i veces por el dispositivo antes de ser completado. Adimensional $\rightarrow C_i / C_0$
- D_i : demanda de servicio. El tiempo total que cada trabajo ha usado el dispositivo antes de terminar. No tiene en cuenta la cola $\rightarrow B_i / C_0 \rightarrow V_i \cdot S_i$

Las variables del sistema en su conjunto llevan un $_0$, y se calculan igual, solo que en vez de calcularse en un solo dispositivo, se calculan en el sistema entero. Son:

- El número de trabajos completados, C_0
- El número de trabajos que llegan al sistema, A_0
- La tasa de llegada al sistema, λ_0
- La productividad del sistema, X_0
- El tiempo de respuesta del sistema, R_0 . Es un promedio.
- El número medio de trabajos en el sistema, N_0

Estas variables se relacionan en cualquier intervalo mediante **leyes operacionales**. Estas se cumplen sólo si se cumple la **hipótesis del equilibrio de flujo**, en la que en un sistema no saturado, para un intervalo grande, los trabajos que llegan se igualarán a la productividad.

- **Ley de Little:** El promedio de trabajos del sistema es la tasa de llegada (o productividad) por el tiempo de respuesta. $N_0 = \lambda_0 * R_0 = X_0 * R_0$. Esto es aplicado a una estación de servicio completa, si solo se aplica a la cola de dicha estación, se intercambia R por W .
- **Ley de la utilización:** la utilización también puede ser la productividad por el tiempo de servicio. $U_i = B_i / T \rightarrow$ (multiplicar ambos lados de la fracción por C_i) $\rightarrow U_i = X_i * S_i$.
- **Ley del flujo forzado:** La productividad es proporcional a la razón de visita. De aquí, la utilización del dispositivo es proporcional a la productividad del sistema y la demanda del servicio del dispositivo. $V_i = X_i / X_0 \rightarrow X_i = X_0 * V_i$. De aquí, $U_i = X_i * S_i = X_0 * V_i * S_i = X_0 * D_i$.
- **Ley general del tiempo de respuesta:** R_0 es la suma del tiempo de respuesta de los dispositivos por la razón de visita de cada uno. $R_0 = \sum_{i=1}^k V_i * R_i$
- **Ley del tiempo de respuesta interactivo:** aplicando la ley de Little a una red cerrada con Z , $R_0 = N_T / X_0 - Z$, siendo $N_T = X_0 * (Z + R_0) = N_Z + N_0$

Todo sistema tiene un límite (cuello de botella), que se encuentra en la estación de servicio de mayor utilización. La demanda de servicio es proporcional a esta. Se debe encontrar la estación con más utilización.

Los **límites optimistas del rendimiento** son la productividad máxima y el tiempo mínimo de respuesta, que actúan como cotas ideales, ya que en la práctica siempre existen esperas que reducen la productividad y aumentan el tiempo de respuesta.

En **sistemas abiertos**, la **tasa máxima de llegada** está limitada por la inversa de la demanda del cuello de botella; al superarla, el sistema se **satura** y deja de cumplirse el equilibrio de flujo. El **tiempo de respuesta mínimo** se obtiene cuando no hay esperas, siendo igual a la **demandas de servicio** total.

En **sistemas cerrados**, con **carga alta** la productividad máxima coincide con la del sistema abierto, al alcanzarse la saturación del cuello de botella. Con **carga baja**, la productividad se obtiene aplicando la **ley de Little** al sistema completo, como el número de trabajos dividido entre la suma de la demanda de servicio y el tiempo de reflexión. El **tiempo de respuesta mínimo** será la demanda de servicio en carga baja, y en carga alta se obtiene mediante la ley de Little, considerando el número de trabajos, la demanda del cuello de botella y el tiempo de reflexión.

El **punto teórico de saturación** permite distinguir entre carga baja y alta y se alcanza cuando el número de trabajos en la red es igual a la demanda del sistema más el tiempo de reflexión dividido entre la demanda de servicio; a partir de ese punto aparecen colas, especialmente en el cuello de botella, que impone los límites de rendimiento. El **análisis de redes de colas** permite calcular todas las métricas del sistema a partir de unos pocos parámetros. En redes cerradas, este cálculo se realiza de forma **iterativa**, evaluando para cada número de trabajos la productividad, el tiempo de respuesta y la ocupación de cada estación hasta alcanzar la carga máxima.